Topic 10 · Teknologi Big Data

Layer Processing: SQL di Atas Hadoop

Hive, Pig, dan Spark SQL



Capaian belajar hari ini

- **Menjelaskan** fungsi layer processing dan perbedaannya dengan layer storage.
- **Menjelaskan** cara kerja, kelebihan, dan kekurangan Hive, Pig, dan Spark SQL.
- **Menjalankan** tiga query (agregasi, join, partisi) pada data kasus kelompok.
- **Memilih dan membenarkan** mesin query dengan bukti pengukuran sendiri.



Luaran pekan ini

PDF Desain Lapisan Processing, dikumpulkan sebelum 8 November 2026 pukul 23.59 WIB.

Bagian 1: fungsi layer processing

Dari data yang tersimpan menjadi hasil yang berguna

Berapa penjualan per kategori per jam kemarin?

Data TokoNusa: 2 juta order per hari (angka contoh). Analis fasih SQL, bukan Java. Alat apa yang paling tepat menjawabnya?

Empat fungsi utama layer processing

Bersihkan

- Buang duplikat dan data rusak
- Samakan format tanggal dan satuan

Ubah bentuk

- Pilih kolom, ubah tipe data
- Simpan ke format kolumnar

Gabung, hitung

- Join antar tabel
- Agregasi: jumlah, rata-rata, hitung

Siapkan hasil

- Tabel ringkasan per hari atau jam
- Siap dibaca layer serving

Layer processing mengubah data mentah di storage menjadi tabel hasil yang siap dibaca dashboard.

Storage lawan processing

Aspek	Storage (Topic 9, HBase)	Processing (Topic 10)
Tugas utama	Menyimpan dan menemukan data	Menghitung dan mengubah data
Pertanyaan khas	Ambil profil pengguna X	Penjualan per kategori per jam
Pola akses	Satu key atau rentang sempit	Membaca banyak baris sekaligus
Kecepatan yang dikejar	Milidetik per permintaan	Menit untuk data besar
Alat contoh	HBase, HDFS	Hive, Pig, Spark SQL

Analogi: storage adalah gudang yang rapi, processing adalah dapur yang mengolah isi gudang menjadi hidangan.

Posisi processing di arsitektur



Processing membaca dari storage dan menulis hasilnya kembali. Keduanya saling melengkapi, bukan saling menggantikan.

Mengapa perlu abstraksi di atas MapReduce

- **MapReduce butuh Java.** Setiap pertanyaan baru berarti program baru.
- **Banyak orang perlu menganalisis data:** analis, data scientist, statistikawan.
- **Abstraksi menjembatani keduanya:** query SQL atau skrip dataflow diterjemahkan menjadi pekerjaan terdistribusi.



Gagasan kunci

Pengguna menulis apa yang diinginkan. Mesin yang memutuskan bagaimana membaginya ke banyak mesin.

Bagian 2: tools layer processing

Cara kerja, kelebihan, dan kekurangan

Peta tools layer processing

Tool	Gaya	Cara menjalankan	Peran di kuliah
Hive	SQL deklaratif	Server dan Tez di atas HDFS	Inti
Spark SQL	SQL dan DataFrame	Mesin di memori	Inti
Pig	Dataflow (Pig Latin)	Skrip menjadi job batch	Opsional
Trino, Flink, dll.	Beragam	Di luar cakupan	Hanya disebut

Tiga tool pertama dibahas hari ini. Tool lain ada, tetapi kuliah ini fokus pada SQL di atas Hadoop.

Versi terkini (Oktober 2026)

Tool	Versi	Dirilis	Catatan
Hive	4.2.1	24 Agustus 2026	Rilis perbaikan. Image Docker apache/hive:4.2.1.
Spark	4.2.0	14 Juli 2026	Hanya Scala 2.13. Python lewat pip install pyspark.
Pig	0.18.0	Tidak tercantum	Rilis terbaru di situs resmi.

Hive 4.2.0 mensyaratkan JDK 21 sebagai minimum. Kita memakai Docker agar Java sudah tersedia di dalam image.

Arsitektur Hive



Hive menyimpan skema di Metastore dan data di HDFS (skema-on-read). Pada Hive 4.x, query dieksekusi dengan Tez, bukan MapReduce.

Perjalanan satu query Hive

1
Kirim query

SQL dari Beeline atau aplikasi

2
Analisis

Cek tabel dan kolom di Metastore

3
Optimasi

Susun rencana yang efisien

4
Eksekusi

Tez menjalankan tugas paralel

5
Hasil

Dikembalikan atau ditulis ke tabel

Pengguna hanya menulis SQL. Pembagian kerja ke banyak mesin dilakukan otomatis oleh Hive dan Tez.

Tabel Hive: managed dan external

Managed

- Hive memiliki datanya
- DROP TABLE menghapus data
- Cocok untuk data olahan

External

- Data tetap di lokasi sendiri
- DROP TABLE hanya menghapus metadata
- Cocok untuk data mentah yang dipakai bersama

Aturan praktis: data mentah dari sumber dibuat external, hasil olahan boleh managed.

Format file: teks dan Parquet

Teks (CSV atau JSON)

- Dibaca baris demi baris, semua kolom
- Mudah dibuka manusia
- Kompresi dan skema tidak tertanam

Parquet atau ORC (kolumnar)

- Hanya kolom yang dibutuhkan dibaca
- Kompresi baik, skema tertanam
- Jauh lebih cepat untuk agregasi

Format file sering lebih menentukan kecepatan daripada pilihan mesin query.

Partisi: baca lebih sedikit

```
CREATE EXTERNAL TABLE order_baru (
  id BIGINT,
  kategori STRING,
  waktu TIMESTAMP,
  nilai DOUBLE)
PARTITIONED BY (tgl STRING)
STORED AS PARQUET
LOCATION '/data/tokonusa/order';
```

Perhatikan

- Satu folder per nilai tgl
- Query dengan WHERE tgl hanya membaca folder itu
- Jangan partisi di kolom dengan terlalu banyak nilai unik, misalnya user_id

Hive: kelebihan dan kekurangan

Kelebihan

- SQL yang dikenal analis
- Skala ke data sangat besar
- Terhubung ke alat BI lewat JDBC
- Partisi dan format kolumnar

Kekurangan

- Latensi menit, bukan milidetik
- Bukan untuk transaksi per baris
- Butuh komponen: server, Metastore
- Perlu penyetelan memori dan partisi

Pilih Hive bila penggunanya analis SQL dan hasil dalam hitungan menit sudah cukup.

Cara kerja Pig

1
Tulis skrip

Langkah demi langkah dalam Pig Latin

2
Rencana logika

Pig memahami urutan langkah

3
Jadi job

Diterjemahkan ke job terdistribusi

4
Eksekusi

Berjalan di klaster

5
Simpan hasil

STORE ke HDFS

Pig meminta pengguna menulis alur data secara berurutan, bukan hanya hasil akhir seperti SQL.

Pig Latin: dataflow langkah demi langkah

```
order = LOAD '/data/order' USING PigStorage(',')
  AS (id:long, kategori:chararray, nilai:double);
besar = FILTER order BY nilai > 500000;
per_kat = GROUP besar BY kategori;
hasil = FOREACH per_kat GENERATE group,
  SUM(besar.nilai);
STORE hasil INTO '/hasil/pig';
```

Kapan relevan

- Cocok untuk ETL bertahap
- Berbeda dengan SQL yang deklaratif
- Opsional di kuliah ini

Pig: kelebihan dan kekurangan

Kelebihan

- Alur transformasi mudah dibaca bertahap
- Cocok untuk ETL dan pembersihan
- Skema fleksibel saat memuat data

Kekurangan

- Bahasa khusus, bukan SQL
- Komunitas dan materi lebih sedikit
- Tidak interaktif, hasil lewat job batch

Pig berguna untuk memahami dataflow, tetapi di kuliah ini perannya opsional.

Cara kerja Spark SQL

1. **Tulis query**
   SQL atau DataFrame
2. **Optimizer**
   Catalyst menyusun rencana terbaik
3. **Rencana fisik**
   Dibagi menjadi tugas paralel
4. **Eksekusi**
   Executor mengolah data di memori
5. **Hasil**
   Tampil atau ditulis ke storage

Data perantara disimpan di memori bila cukup, sehingga sering lebih cepat dari mesin yang menulis ke disk di tiap tahap.

Spark SQL: query yang sama, mesin berbeda

```
df = spark.read.parquet("/data/tokonusa/order")
df.createOrReplaceTempView("order_baru")

spark.sql("""
  SELECT kategori, SUM(nilai) AS penjualan
  FROM order_baru
  WHERE tgl = '2026-10-15'
  GROUP BY kategori""").show()
```

Bandingkan

- Sintaks SQL hampir sama
- Diproses di memori
- DataFrame API setara dengan SQL

Spark SQL: kelebihan dan kekurangan



Kelebihan

- Cepat berkat pemrosesan di memori
- SQL dan DataFrame dalam satu mesin
- Dipakai juga untuk streaming dan ML
- Dapat membaca Metastore Hive



Kekurangan

- Boros memori, rawan kehabisan memori
- Penyetelan shuffle dan skew rumit
- Biaya sumber daya lebih tinggi
- Versi dan lingkungan perlu dijaga

Pilih Spark SQL bila kecepatan dan fleksibilitas penting dan memori tersedia.

Bagian 3: memilih dan membenarkan

Justifikasi setiap tool dengan bukti, bukan kebiasaan

Justifikasi per tool

Tool	Dibenarkan bila	Kurang tepat bila	Bukti yang diminta
Hive	Pengguna analis SQL, laporan batch, data besar di HDFS, hasil dalam menit cukup	Butuh respons detik atau transaksi per baris	Waktu median tiga kali, teks lawan Parquet
Spark SQL	Butuh cepat, logika kompleks, atau sekaligus streaming dan ML, memori tersedia	Memori terbatas, atau tim hanya butuh laporan harian sederhana	Waktu query yang sama di Spark, catatan memori
Pig	Alur ETL bertahap, tim sudah memakai Pig, skrip warisan	Pengguna butuh SQL atau alat BI interaktif	Skrip berjalan stabil, alasan memilihnya

Memilih mesin query

Kriteria	Hive	Pig	Spark SQL
Pengguna utama	Analis SQL	Pengembang pipeline	Analis dan developer
Gaya	SQL deklaratif	Dataflow	SQL dan DataFrame
Kecepatan	Menit	Menit	Lebih cepat di memori
Kebutuhan memori	Sedang	Sedang	Tinggi
Peran di kuliah	Inti	Opsional	Inti

Tabel ini titik awal diskusi. Keputusan akhir harus berdasarkan data dan ukuran project Anda.

Demo: laporan penjualan per jam

```
SELECT kategori,
       HOUR(waktu) AS jam,
       SUM(nilai)  AS penjualan
FROM order_baru
WHERE tgl = '2026-10-15'
GROUP BY kategori, HOUR(waktu)
ORDER BY penjualan DESC;
```

Yang diukur

- Jalankan pada tabel teks dan tabel Parquet
- Catat waktu, ulangi 3 kali
- Bandingkan hasilnya, harus sama

Cara mengukur waktu dengan adil

- **Data cukup besar,** agar yang terukur bukan waktu start-up.
- **Jalankan 3 kali,** catat median, bukan yang tercepat.
- **Ubah satu hal setiap kali:** format file, ukuran data, atau mesin.
- **Catat lingkungan:** versi, memori, jumlah core.



Jebakan umum

Membandingkan dua mesin dengan format file berbeda. Hasilnya mengukur format, bukan mesin.

Contoh Catatan Keputusan Desain

Bagian	Isi untuk TokoNusa
Keputusan	Laporan penjualan harian memakai Hive pada tabel Parquet berpartisi tanggal.
Konteks	Analis memakai SQL, laporan dibuat sekali per hari, data order 2 juta baris per hari.
Alternatif ditolak	Spark SQL: lebih cepat di memori, tetapi tim analis belum memakainya dan biaya memori lebih tinggi.
Konsekuensi	Latensi menit, bukan detik. Bila kebutuhan menjadi per menit, perlu mesin lain.
Bukti	Waktu median 3 kali pada data 1x dan 10x, format teks dan Parquet.

Aktivitas hari ini

1. **Muat data**
   Sampel 100 sampai 500 MB, atau generator dosen.
2. **Dua tabel Hive**
   Satu teks, satu Parquet. Screenshot.
3. **Tiga query**
   Agregasi, join, dan query kolom partisi.
4. **Ukur waktu**
   Teks lawan Parquet, data 1x dan 10x, median 3 kali.
5. **Ulangi di Spark SQL**
   Satu query, catat waktu dan beda sintaks.
6. **Analisis**
   Mengapa format dan partisi berpengaruh; bila data 100x?
7. **Catatan Keputusan Desain**
   Mesin query yang dipilih dan alasannya.
8. **Diagram v0.2**
   Tambah lapisan processing di atas storage.

Checkpoint: tabel Hive terbentuk dan query pertama mengembalikan hasil dari data kelompok.

Tugas lanjutan dan persiapan

- **Tugas:** PDF Desain Lapisan Processing berisi laporan instalasi, tiga query, tabel waktu, perbandingan Hive dan Spark SQL, serta alasan pemilihan.
- **Batas:** EMAS3, sebelum 8 November 2026 pukul 23.59 WIB.
- **Bacaan:** dokumentasi Hive di hive.apache.org dan panduan Spark SQL di spark.apache.org.
- **Persiapan Topic 11:** pastikan Docker berjalan di laptop dan jalankan profil kafka sekali sebelum kelas.



Catatan versi

Hive 4.x memakai Tez. Image apache/hive:4.2.1 sudah membawa Java yang dibutuhkan, jadi Anda tidak perlu memasang Java untuk Hive.